

Previsao de Vendas XPTO

Relatorio Final Corrigido - Rossmann Store Sales Series Temporais e Inteligencia Artificial

Este relatorio apresenta a versao corrigida do projeto, incorporando os reparos metodologicos: a serie diaria completa foi preservada, os dias sem vendas foram mantidos, a LSTM foi normalizada sem data leakage e o scaler ajustado no treino foi salvo e reutilizado na inferencia futura.

Checklist dos Criterios de Avaliacao

Criterio	Como foi cumprido
Problema e objetivos quantitativos	Previsao diaria de vendas da Loja 1; mais de 500 registos; MAPE alvo inferior a 20%.
2 beneficios empresariais	Otimizacao de stock e apoio ao planeamento comercial/promocional.
Recolha e pre-processamento	Dataset Rossmann realista; serie diaria completa; dias fechados mantidos; lags e medias moveis.
Selecao e treino de modelos	ARIMA, SARIMA semanal e LSTM treinados e comparados.
Avaliacao do modelo	MAE, RMSE e MAPE seguro calculados no conjunto de teste.
Erro inferior a 20%	Todos os modelos ficaram abaixo de 20% em MAPE seguro; melhor MAPE: ARIMA 14.62%, melhor MAE/RMSE: SARIMA.
Limitacoes e melhorias	Secoos 7 e 8 apresentam limitacoes e propostas futuras.
Graficos e visualizacoes	Figuras de serie temporal, distribuicao, sazonalidade, treino, teste e previsao futura.
Codigo entregue	Scripts .py organizados na pasta notebooks, modelo LSTM e scaler salvo em models/.

1. Definicao do Problema

1.1 Contexto

A XPTO pretende melhorar o planeamento de stock e a preparacao para periodos de maior procura. Para isso, foi desenvolvido um projeto de previsao de vendas utilizando dados historicos diarios da Rossmann, um dataset realista de retalho.

1.2 Problema Escolhido

O problema escolhido foi prever as vendas diarias da Loja 1. A escolha de uma loja especifica torna a serie temporal clara e interpretavel, mantendo volume de dados suficiente.

1.3 Objetivos Quantitativos

- Usar um dataset realista com pelo menos 500 registos; a Loja 1 possui 942 registos diarios e o dataset processado possui 912 registos.
- Dividir cronologicamente a serie em 729 registos de treino e 183 registos de teste.
- Treinar e comparar ARIMA, SARIMA e LSTM.
- Atingir MAPE seguro inferior a 20% no conjunto de teste.
- Gerar previsao futura ate dezembro de 2015, com foco em novembro e dezembro.

1.4 Beneficios para a Empresa

- Otimizar stock, reduzindo rupturas e excesso de produtos.
- Apoiar decisoes de compras, promocoos e alocao de recursos no fim de ano.

2. Recolha e Pre-processamento dos Dados

2.1 Dataset

Foi usado o Rossmann Store Sales, dataset publico de vendas diarias. O ficheiro train.csv inclui Store, Date, Sales, Customers, Open, Promo, StateHoliday e SchoolHoliday. O ficheiro store.csv contem dados complementares das lojas.

Indicador	Valor
Linhas no train.csv	1.017.209
Numero de lojas	1115
Loja analisada	1
Registos diarios da Loja 1	942
Dias com loja fechada mantidos	161
Dias com vendas zero mantidos	161
Periodo da Loja 1	2013-01-01 a 2015-07-31
Media de vendas	3945.70
Minimo / Maximo de vendas	0 / 9528

2.2 Correcao Metodologica: Manter Dias Sem Vendas

Os dias fechados e os dias com vendas iguais a zero foram mantidos. Esta decisao preserva a frequencia diaria da serie, permitindo que modelos sazonais como SARIMA utilizem corretamente o ciclo semanal de 7 dias. A coluna Open foi mantida como informacao explicativa da abertura da loja.

2.3 Features Criadas

- Conversao da coluna Date para datetime.
- Variaveis de calendario: dia, mes, ano, semana do ano, novembro e dezembro.
- Variavel is_state_holiday criada a partir de StateHoliday.
- Lags: lag_1, lag_7, lag_14 e lag_30.
- Medias moveis: MA7, MA14 e MA30.
- Remocao apenas das primeiras linhas incompletas geradas por lags e medias moveis.

Apos o pre-processamento, o dataset final ficou com 912 registos e 22 colunas.

2.4 Divisao Treino/Teste

Os dados foram divididos sem embaralhamento. O treino possui 729 registos, de 2013-01-31 a 2015-01-29. O teste possui 183 registos, de 2015-01-30 a 2015-07-31.

3. Analise Exploratoria




Figura 1: Serie temporal diaria de vendas da Loja 1.




Figura 2: Distribuicao das vendas.




Figura 3: Media de vendas por mes.




Figura 4: Media de vendas por dia da semana.




Figura 5: Baseline pela media global.




Figura 6: Baseline naive pelo dia anterior.

A analise mostra variacao diaria, dias sem vendas, padroes semanais e diferencas mensais. Isso justifica o teste de modelos com memoria temporal e sazonalidade semanal.

4. Selecao e Treino dos Modelos

4.1 ARIMA

Foi treinado um $ARIMA(1,1,1)$, usado como modelo estatistico classico de referencia.

4.2 SARIMA

Foi treinado um $SARIMA(1,1,1)(1,1,1,7)$. O periodo sazonal 7 e coerente porque a serie diaria completa foi preservada, incluindo dias fechados.

4.3 LSTM sem Data Leakage

A LSTM recebeu sequencias dos 30 dias anteriores para prever o dia seguinte. A normalizacao foi corrigida para evitar data leakage: o `MinMaxScaler` foi ajustado apenas no periodo de treino, salvo em `models/sales_scaler.pkl` e reutilizado na previsao futura.




Figura 7: Evolucao da loss durante o treino da LSTM.

5. Avaliacao dos Modelos

5.1 Metricas

Foram usadas MAE, RMSE e MAPE seguro. O MAPE seguro ignora pontos em que a venda real e zero, evitando divisao por zero em dias de loja fechada.

5.2 Resultados

Modelo	MAE	RMSE	MAPE seguro
ARIMA(1,1,1)	1306.89	1924.73	14.62%
SARIMA(1,1,1)(1,1,1,7)	705.99	1112.04	15.36%
LSTM corrigida	1004.50	1445.16	14.68%

O ARIMA obteve o menor MAPE seguro (14.62%), mas o SARIMA apresentou o melhor desempenho operacional em MAE e RMSE (705.99 e 1112.04), alem de prever valores proximos de zero em dias fechados. Por isso, o SARIMA e considerado o melhor modelo geral para esta serie corrigida. A LSTM tambem cumpriu o criterio de erro inferior a 20%, com MAPE seguro de 14.68%, agora sem data leakage.




Figura 8: Vendas reais vs previsoes da LSTM no teste.

6. Previsao para o Fim de Ano

A previsao futura foi gerada de 01/08/2015 a 31/12/2015. O foco de analise foi novembro e dezembro de 2015.

Indicador	Valor
Periodo previsto completo	2015-08-01 a 2015-12-31
Media prevista no periodo completo	3451.36
Minimo / Maximo no periodo completo	1564.30 / 4364.20
Media prevista em novembro/dezembro	3403.20
Minimo / Maximo em novembro/dezembro	2631.49 / 4101.92
Total previsto novembro 2015	101427.52
Total previsto dezembro 2015	106167.42




Figura 9: Historico recente e previsao LSTM ate dezembro de 2015.

A previsao futura da LSTM e recursiva, ou seja, cada previsao e reutilizada para prever o dia seguinte. Isso permite projetar varios meses, mas pode acumular erro.

7. Limitacoes

- O projeto analisa apenas a Loja 1.
- A previsao futura recursiva pode acumular erro.
- A LSTM nao recebe calendario futuro de promocoos e feriados.
- O MAPE precisa ser calculado de forma segura devido aos dias com vendas zero.
- Variaveis do store.csv seriam mais uteis em um modelo multiloja.

8. Melhorias Futuras

- Usar SARIMAX com variaveis externas futuras.
- Criar modelo multiloja com informacoes do store.csv.
- Testar modelos supervisionados como XGBoost e Random Forest.
- Aplicar validacao temporal com multiplas janelas.
- Incluir calendario futuro de promocoos, feriados e abertura da loja.

9. Conclusao

A versao corrigida cumpre os requisitos principais: usa dataset realista, mantem 912 registos processados, preserva a frequencia diaria, evita data leakage na LSTM, salva modelo e scaler, compara ARIMA/SARIMA/LSTM e gera previsao para o fim do ano. O SARIMA apresentou melhor desempenho geral em MAE/RMSE, enquanto todos os modelos ficaram abaixo de 20% em MAPE seguro.

10. Anexos

10.1 Scripts

- notebooks/00_check_rossmann_dataset.py
- notebooks/01_explore_data.py
- notebooks/02_process_features.py
- notebooks/03_train_test_split.py
- notebooks/04_train_ARIMA.py
- notebooks/05_train_SARIMA.py
- notebooks/06_train_LSTM.py
- notebooks/07_predict_future_LSTM.py

10.2 Outputs

- outputs/arima_results.csv
- outputs/sarima_results.csv
- outputs/lstm_results.csv
- outputs/lstm_future_forecast.csv
- outputs/lstm_forecast_nov_dec_2015.csv
- models/lstm_model.keras
- models/sales_scaler.pkl